Proyecto – Etapa 2 Semantic Web (MISIS)

Competency Questions

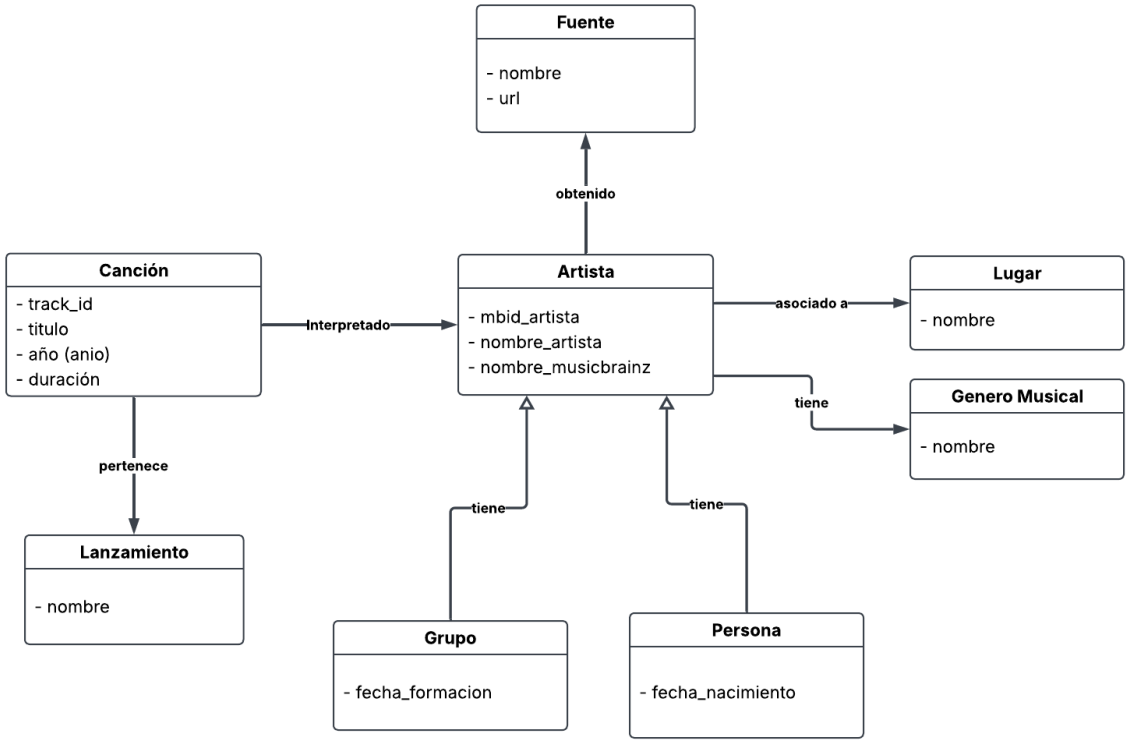
#	Pregunta	Tipo	Respuesta Esperada	SPARQL
1	¿Qué canciones están asociadas a un artista determinado, cuáles son los lanzamientos a los que pertenecen y qué información se encuentra disponible sobre su año, duración y género musical?	Recuperación	Se espera un listado de canciones de un artista seleccionado, donde tendremos título, lanzamiento, año, duración y genero musical.	SELECT DISTINCT, OPTIONAL, ORDER BY
2	¿Qué canciones presentan múltiples clasificaciones de género musical, cuáles son los géneros asociados y qué artistas interpretan dichas canciones?	Recuperación	Se espera obtener canciones con múltiples clasificaciones musicales donde tendremos título, géneros principales y artistas asociados.	SELECT DISTINCT FILTER, ORDER BY
3	¿Qué canciones registradas entre 1980 y 2010 presentan una clasificación de género ambigua y cuáles son sus géneros principales y los artistas asociados?	Recuperación	Se espera canciones registradas entre 1980 y 2010 con clasificación ambigua, donde tendremos los géneros principales y artistas asociados.	SELECT DISTINCT, FILTER (año y clasificación anmbigua)
4	¿Qué canciones de distintos artistas comparten un mismo título y en qué lanzamientos se encuentran registradas?	Navegación	Se espera una lista de canciones con títulos coincidentes pertenecientes a artistas diferentes. Obtendremos los artistas y lanzamientos correspondientes.	SELECT DISTICNT, FILTER, Relaciones entre entidades.
5	A partir de un artista seleccionado mediante su identificador de MusicBrainz, ¿Qué géneros musicales están asociados a dicho artista?	Navegación	Se espera un listado de géneros musicales de un artista seleccionado mediante su MBID.	SELECT DISTINCT, ORDER BY Relaciones entre Artista y Genero
6	¿Cuáles son los diez artistas con mayor cantidad de canciones registradas dentro de un género musical seleccionado y cuántas canciones tiene cada uno?	Agregación	Queremos obtener el top 10 artistas con mayor numero de canciones dentro de un genero seleccionado. Se organizará indicando la cantidad correspondiente a cada uno.	MIN, COUNT(DISTINCT), GROUP BY, ORDER BY, DESC, LIMIT

7	¿Qué canciones tienen una duración superior al promedio de las canciones de su mismo género musical y cuáles son sus artistas asociados?	Agregación	Se espera obtener canciones cuya duración supera el promedio de su género, donde tendremos título, artista, genero, duración y promedio correspondiente.	AVG, GROUP BY, FILTER Subconsulta.
8	¿Cómo se distribuyen las canciones según su género musical y el país o región de sus artistas, y cuántas canciones diferentes corresponden a cada combinación?	Agregación	Se espera la cantidad de canciones diferentes para cada combinación de genero música, con país y región del artista.	COUNT(DISTINCT), GROUP BY, ODER BY

Principales decisiones de modelamiento

En el modelo conceptual original, se mantuvo la clase Canción como entidad principal, debido a que el conjunto de datos esta compuesto principalmente por registros de canciones. Para la representación de los artistas, lanzamientos, géneros, lugares y fuentes se decidió dejarlos independientes.

Modelo conceptual en la Etapa 1:



Elementos Conservados del modelo Original

Como se puede observar en la imagen, conservamos las relaciones: Canción-Artista (interpretado) y Canción-Lanzamiento (pertenece), que permiten identificar los intérpretes y lanzamientos asociados a cada canción. También mantuve las relaciones Artista-Género Musical (tiene) y Artista-Lugar (asociado a) que me ayudan a representar los géneros asociados a los artistas y su información de origen.

Además, conserve las Sub-Clases Persona y Grupo de Artista, manteniendo sus atributos de fecha de nacimiento y fecha de formación. La relación Artista–Fuente (obtenido) también se mantuvo para representar la procedencia de la información integrada.

Estas decisiones me permitieron abordar las preguntas de competencia recuperando una gran cantidad de información sobre las canciones de un artista (Pregunta 1), la identificación de canciones con títulos coincidentes (Pregunta 4), consultar de géneros asociados a un artista (Pregunta 5) e identificar la información geográfica de los artistas que me permite identificar cuántas canciones hay por género musical y país o región (Pregunta 8).

Cambios realizados respecto a la Etapa 1

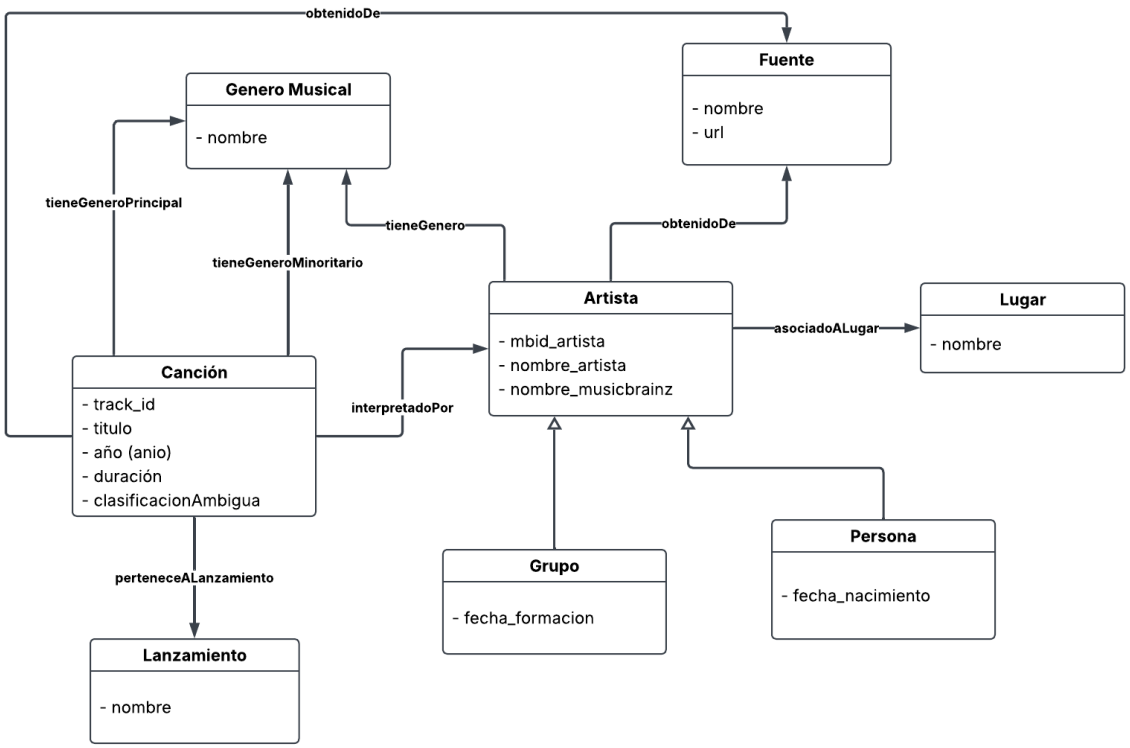
A partir de las 8 preguntas de competencia y de integración de información adicional de Tagtraum, se requirió ampliar el modelo conceptual. Antes, los géneros musicales estaban relacionados únicamente con los artistas, por lo que fue necesario incorporar propiedades que permitieran representar también los géneros asociados directamente a las canciones. A su vez, se realizaron arreglos entre las relaciones de las entidades.

Elementos Añadidos

- **tieneGeneroPrincipal:** relaciona una canción con su género musical principal.
- **tieneGeneroMinoritario:** permite representar un género musical minoritario asociados a una canción.
- **clasificacionAmbigua:** permite identificar las canciones que presentan clasificación musical ambigua.
- **Relación Canción–Fuente (obtenidoDe):** permite identificar la procedencia de la información asociada a las canciones.

Estas modificaciones nos permiten responder las preguntas asociadas clasificaciones musicales (Pregunta 2 y 3), identificar los artistas con más canciones de un género (Pregunta 6), realizar comparaciones entre las duraciones de las canciones según un género (Pregunta 7) y analizar la distribución de géneros por región o país.

Modelo Conceptual en Etapa 2:



Construcciones RDFS y OWL Utilizadas

Construcciones RDFS

Se utilizaron construcciones RDFS para representar el modelo conceptual. Esto me permitió establecer jerarquías entre clases, definir características de las propiedades y describir los elementos de la ontología.

En primer lugar, se establecieron jerarquías del modelo. Un ejemplo claro es Persona y Grupo ya que se definieron como subclases de Artistas, porque compartían características generales, pero también atributos propios.

También se definieron dominios y rangos de las propiedades. Sabemos que el dominio indica la clase del sujeto de una relación, mientras que el rango indica la clase de su objeto. Por ejemplo, interpretadoPor tiene como dominio Canción y como rango Artista porque relaciona una canción con el artista. Asimismo, dejamos claros los tipos de datos de los atributos como año o duración usando xsd.

Se añadieron labels y comments con el objetivo de asignar nombres y descripciones a las clases y propiedades, facilitando la comprensión de la ontología.}}

Axiomas OWL

#	Tipo de Construcción	Axioma	Porque es Verdadero en el Dominio
1	Clases disjuntas	Cancion owl:disjoinWith Artista	Una canción es una obra musical y un artista es la persona que la interpreta.
2	Clases disjuntas	Persona owl:disjoinWith Grupo	Una persona hace alusión a un individuo, mientras que un grupo hace alusión a varios individuos
3	Propiedades Inversas	interpretadoPor owl:inverseOf interpreta	Si una canción es interpretada por un artista, ese artista también interpreta dicha canción.
4	Propiedades inversas	perteneceALanzamiento owl:inverseOf contieneCancion	Si una canción pertenece a un lanzamiento, ese lanzamiento también contiene dicha cancion.
5	Propiedad simétrica	tieneMismoTituloQue a owl:SymmetricProperty	Si dos canciones comparten el mismo título, la relación se cumple en ambos sentidos.
6	Propiedad funcional	duracion a owl:FunctionalProperty	Cada canción tiene un valor de duración registrado único
7	Cardinalidad exacta	Cancion ⊑ (= 1 trackId)	Cada canción debe tener un solo identificador (track_id)
8	Clase equivalente.	CancionClasificada ≡ Cancion ⊓ ∃tieneGeneroPrincipal.GeneroMusical	Una canción se considera clasificada cuando tiene al menos un genero musical principal.

Implementación y Principales problemas encontrados

Implementación

Los archivos de ontología e instancias se generaron mediante programas desarrollados en Python, utilizando la biblioteca RDFLib (generación_ontologia.py y generación_instancias.py). Para la parte de instancias, se utilizaron las 100.000 canciones de la Etapa 1, junto con la información enriquecida de MusicBrainz y los datos adicionales obtenidos de Tagtraum.

Posteriormente, ambos archivos se cargaron en Apache Jena Fuseki con la ayuda de Docker. Se pudo registrar 157 tripletas por parte de la ontología y 1.182.397 tripletas por parte de las instancias.

Principales problemas

Una dificultad que tuve fue la integración de la información de MusicBrainz y Tagtraum, debido a que no todas las canciones contaban con datos disponibles en ambas fuentes. Por esta razón, se conservó la información existente almacenada y se incorporaron los datos adicionales únicamente cuando se encontraban coincidencias.

Otra dificultad se presentó al subir el proyecto a GitHub, debido a que el archivo instances.ttl superaba el límite de tamaño permitido. Este problema se solucionó utilizando Git LFS, lo que permitió almacenar el archivo y publicar correctamente el repositorio.